

Uniwersytet Wrocławski
Wydział Matematyki i Informatyki
Instytut Matematyczny
Indywidualne Studia
Informatyczno-Matematyczne

Dominik Biernacki

**Analiza i zastosowania procesów stochastycznych
w algorytmach anonimizujących dane**

Praca licencjacka
napisana pod kierunkiem
prof. dr. hab. Dariusza Buraczewskiego

Wrocław, 2025

Spis treści

1	Wstęp	3
1.1	Motywacja	3
1.2	Prywatność różnicowa	3
1.3	Istniejące prace	3
1.4	Struktura pracy	4
2	Superskoncentrowany spacer losowy	4
2.1	Ruch Browna	4
2.2	Konstrukcja SSL	6
2.3	Probabilistyczne własności SSL	7
2.4	Szereg nieskończony	9
3	Algorytmy anonimizujące dane	11
3.1	Ogólny schemat algorytmu	11
3.2	Schemat Laplace’a	13
3.3	Algorytm wykorzystujący SSL	14
4	Eksperymenty	15
4.1	Implementacja SSL	15
4.2	Przejście z miary znakowej na miarę probabilistyczną	16
4.3	Porównanie algorytmów	16
4.4	Wyniki	17

1 Wstęp

1.1 Motywacja

W dobie dynamicznego rozwoju sztucznej inteligencji i uczenia maszynowego coraz częściej korzystamy z algorytmów, które potrafią wydobywać z pozornie chaotycznych danych istotne i wartościowe informacje. Proces ten – polegający na wykrywaniu wzorców, zależności i trendów – znajduje zastosowanie w niemal każdej dziedzinie życia: od medycyny, przez finanse, aż po marketing. Jednakże źródłem tej wiedzy bardzo często są dane o ludziach – dane osobowe, medyczne, lokalizacyjne, preferencyjne – które niejednokrotnie mają charakter wrażliwy i wymagają szczególnej ochrony.

Wyobraźmy sobie zbiór danych zawierający informacje o nawykach zdrowotnych, historii chorób i stylu życia tysięcy osób. Analiza takiego zbioru mogłaby prowadzić do odkrycia cennych korelacji, na przykład między aktywnością fizyczną a skutecznością określonych terapii. Taka wiedza mogłaby zrewolucjonizować podejście do leczenia wielu chorób. Jednocześnie jednak niewłaściwe przetwarzanie tych danych mogłoby narazić prywatność jednostek i doprowadzić do poważnych nadużyć.

Właśnie w tym miejscu pojawia się potrzeba stosowania algorytmów prywatyzujących dane – rozwiązań, które pozwalają zachować równowagę między użytecznością danych a ochroną prywatności. W niniejszej pracy przyjrzymy się różnym podejściom do prywatyzacji danych, ich zastosowaniom oraz wyzwaniom, jakie stawiają przed badaczami i inżynierami danych.

1.2 Prywatność różnicowa

Aby móc mówić o algorytmach prywatyzujących dane i je analizować, musimy najpierw zdefiniować, czym matematycznie jest prywatność algorytmu. Obecnie najczęściej stosowanym pojęciem jest *prywatność różnicowa*. Intuicyjnie oznacza ona, że usunięcie lub dodanie pojedynczej obserwacji do zbioru danych nie powinno w istotny sposób wpłynąć na wynik działania różnicowo prywatnego algorytmu przyjmującego ten zbiór na wejściu.

Definicja. Algorytm $\mathcal{A}$ jest ε -różnicowo prywatny, jeśli dla dowolnych dwóch zbiorów danych $\mathcal{D}$ i $\mathcal{D}'$, różniących się co najwyżej jedną obserwacją, oraz dla dowolnego mierzalnego zbioru wyników algorytmu $\mathcal{S}$ zachodzi:

$$\frac{\mathbb{P}[\mathcal{A}(\mathcal{D}) \in \mathcal{S}]}{\mathbb{P}[\mathcal{A}(\mathcal{D}') \in \mathcal{S}]} \leq \exp(\varepsilon),$$

gdzie prawdopodobieństwo obliczane jest względem losowości algorytmu $\mathcal{A}$.

Zauważmy, że powyższa definicja odpowiada wcześniej przedstawionej intuicji. Dla małych wartości ε wyrażenie $\exp(\varepsilon)$ przyjmuje wartości minimalnie większe od 1, a ponieważ definicja jest symetryczna (można zamienić miejscami $\mathcal{D}$ i $\mathcal{D}'$), otrzymujemy, że $\mathbb{P}[\mathcal{A}(\mathcal{D}) \in \mathcal{S}] \approx \mathbb{P}[\mathcal{A}(\mathcal{D}') \in \mathcal{S}]$. Ponadto, z definicji tej wynika, że $\mathbb{P}[\mathcal{A}(\mathcal{D}) \in \mathcal{S}] \neq 0$ dla każdych $\mathcal{D}$ i $\mathcal{S}$.

1.3 Istniejące prace

Punktem wyjścia niniejszej pracy są dwie publikacje poświęcone temu samemu zagadnieniu. Pierwszą z nich jest książka [DR14], w której przedstawiono podstawy algorytmów anonimizujących dane, w tym definicję prywatności różnicowej oraz schemat Laplace’a – najprostszy algorytm służący do anonimizacji. Drugą publikacją jest praca [BSV24], w której autorzy najpierw skonstruowali tzw. superskoncentrowany spacer losowy, a następnie wykorzystali go do zmodyfikowania schematu Laplace’a w celu zwiększenia użyteczności zaburzonych danych.

1.4 Struktura pracy

W dalszej części pracy przedstawimy najważniejsze wyniki obu omawianych publikacji, przybliżymy intuicje stojące za zaprezentowanymi algorytmami oraz dokonamy oceny ich praktycznej przydatności.

Rozpocznemy od konstrukcji superskoncentrowanego spaceru losowego, który stanowi podstawowy składnik jednego z analizowanych algorytmów.

Następnie omówimy dwa podejścia do anonimizacji danych: klasyczny schemat Laplace’a oraz algorytm oparty na skonstruowanym wcześniej procesie stochastycznym.

W końcowej części zaprezentujemy wyniki eksperymentów przeprowadzonych na rzeczywistym zbiorze danych. Do pracy dołączona jest implementacja omawianych metod, dostępna pod adresem: <https://github.com/DominikBiernacki/Algorytmy-Anonimizujace-Dane>.

2 Superskoncentrowany spacer losowy


Zanim przejdziemy do omawiania algorytmów prywatyzujących dane, przyjrzymy się kluczowemu składnikowi jednego z nich – superskoncentrowanemu spacerowi losowemu (nazywanemu dalej SSL). W tym rozdziale przedstawimy jego konstrukcję opisaną w pracy [BSV24], a także omówimy najważniejsze własności probabilistyczne. Na zakończenie rozważymy możliwą modyfikację SSL w kierunku modelu z czasem ciągłym.

2.1 Ruch Browna

Aby lepiej zrozumieć konstrukcję SSL, rozpoczniemy od omówienia konstrukcji ruchu Browna z wykorzystaniem tzw. funkcji czapkowych. Będziemy je definiować poziomami na odcinku $[0, 1]$, zgodnie z ilustracją na rysunku 1.

Na poziomie $\mathcal{L}$ znajduje się $2^{\mathcal{L}-1}$ funkcji, z których każda posiada „czapkę” (kształt funkcji) o długości $2^{-\mathcal{L}+1}$ przesuniętą odpowiednio w obrębie odcinka.

Wyjątek stanowi funkcja ϕ_1 znajdująca się na poziomie 0, zdefiniowana jako $\phi_1(x) = x$.



Rysunek 1: Funkcje czapkowe $\phi_1, \phi_2, \dots, \phi_8$.

Definicja. *Trajektorię ruchu Browna* nazwiemy procesem stochastycznym $B(t)$ spełniającym:

- $B(0) = 0$,
- Dla każdych $t > s$, $B(t) - B(s)$ jest zmienną losową o rozkładzie $\mathcal{N}(0, t - s)$,
- Dla każdych $t > s$, zmienna $B(t) - B(s)$ jest niezależna od zmiennej $B(s)$,
- Funkcja $t \mapsto B(t)$ jest ciągła prawie na pewno.

Korzystając z funkcji czapkowych, możemy w prosty sposób generować trajektorie ruchu Browna na odcinku $[0, 1]$. Przedstawimy teraz ideę tej konstrukcji. Będziemy chcieli zapisać trajektorię jako sumę funkcji czapkowych pomnożonych przez odpowiednie zmienne losowe.

Zauważmy, że jedyną funkcją czapkową przyjmującą niezerową wartość w punkcie 1 jest ϕ_1 . Pomnóżmy ją więc przez zmienną losową o rozkładzie $\mathcal{N}(0, 1)$. Następnie rozważmy punkt $1/2$ – wpływ na wartość procesu w tym punkcie mają ϕ_1 oraz ϕ_2 . Ponieważ współczynnik przy ϕ_1 został już ustalony, musimy odpowiednio dobrać zmienną losową towarzyszącą ϕ_2 , tak aby $B(1/2)$ miało właściwy rozkład. Okazuje się, że aby tak się stało, zmienna ta powinna mieć rozkład $\mathcal{N}(0, 1/4)$.


Analogiczne rozumowanie możemy przeprowadzić dla punktów $1/4, 3/4, 1/8, 3/8, 5/8$, i tak dalej (są to tak zwane punkty diadyczne). W ten sposób krok po kroku konstruujemy proces o zadanych własnościach. Ostatecznie trajektorię $B(t)$ możemy zapisać jako:

$$B(t) = \sum_{i=1}^{\infty} Z_i \phi_i(t),$$

gdzie Z_i są niezależnymi zmiennymi losowymi, a oznaczając przez $l(i)$ poziom, na którym znajduje się funkcja ϕ_i , mamy:

$$Z_1 \sim \mathcal{N}(0, 1); \quad Z_i \sim \mathcal{N}(0, 2^{-l(i)-1}), \quad i = 2, 3, \dots$$

Dowód tego, że $B(t)$ skonstruowany w ten sposób jest trajektorią ruchu Browna, pominiemy.



Rysunek 2: Trajektoria ruchu Browna.

Dowodzi się, że tempo odchyień ruchu Browna jest rzędu pierwiastka z czasu. Chcielibyśmy skonstruować proces, którego odchylenia są znacznie wolniejsze. Posłuży nam do tego SSL, który – jak się okaże – charakteryzuje się odchyleniami rosnącymi w tempie logarytmicznym.


2.2 Konstrukcja SSL

Skonstruujemy teraz trajektorię superskoncentrowanego spaceru losowego. Będzie ona podobna do wcześniej opisanej konstrukcji trajektorii ruchu Browna, z dwiema różnicami: zmienne L_i będą teraz niezależnymi zmiennymi losowymi o rozkładzie Laplace’a¹, mającymi stałą wariancję (niezależną od poziomu funkcji ϕ_i); ponadto suma nie będzie nieskończona, lecz ograniczona do $\mathcal{L}$ pierwszych poziomów funkcji czapkowych. Trajektorię $W(t)$ można zapisać jako:

$$W(t) = \sum_{i=1}^n L_i \phi_i(t), \quad L_i \sim \text{Lap}(2\mathcal{L} + 1), \quad n = 2^{\mathcal{L}}$$

Zauważmy, że trajektoria SSL zależy od wyboru parametru $\mathcal{L}$. Na rysunku 3 przedstawiono przykładowe trajektorie dla różnych wartości $\mathcal{L}$. W szczególności warto zwrócić uwagę na oś OY , z której można odczytać, że średni zakres wartości SSL zwiększa się wraz ze wzrostem $\mathcal{L}$.

Zauważmy, że trajektorie te znacznie różnią się od trajektorii ruchu Browna przedstawionej na rysunku 2 – trajektorie SSL wykazują wyraźny trend, wokół którego skupiają się zaburzenia. Zaburzenia te przyjmują postać gwałtownych, powracających skoków – po dużym, nagłym wzroście następuje równie duży, nagły spadek. Jest to właśnie własność *superkoncentracji*, której SSL zawdzięcza nazwę.



Rysunek 3: Trajektoria SSL dla $\mathcal{L} = 5, 7, 9$ oraz 11.

¹Gęstość zmiennej $L \sim \text{Lap}(\lambda)$ wyraża się wzorem $f_L(x) = \frac{1}{2\lambda} \exp\left(-\frac{|x|}{\lambda}\right)$. Ponadto $\mathbb{E}[L] = 0$, $\text{Var}(L) = 2\lambda^2$.

Obie przedstawione konstrukcje definiują trajektorie na odcinku $[0, 1]$. Chcielibyśmy teraz umieć je przedłużyć do półprostej rzeczywistej.

W przypadku ruchu Browna sposób jest prosty – wystarczy „złączać” ze sobą kolejne kopie trajektorii. Strategia ta nie zadziała jednak dla SSL – uprzedzając fakty, kolejne przyrosty SSL są od siebie mocno zależne, dzięki czemu trajektoria odchyła się w tempie logarytmicznym.

Gdybyśmy analogicznie próbowali „łączyć” kolejne trajektorie, sprawilibyśmy, że przyrosty w pewnym momencie przestałyby zupełnie zależeć od przeszłości, co poskutkowałoby pierwiastkowymi odchyleniami (dla $n \in \mathbb{N}$, $W(n)$ byłoby sumą niezależnych zmiennych losowych o tym samym rozkładzie).

Autorzy pracy [BSV24] nie wspominają, jak przedłużyć SSL do nieskończoności, pokazują jednak, jak zrobić to na dowolny odcinek $[0, x]$. Pomysł jest prosty – skonstruujemy trajektorię $W'(t)$ na odcinku $[0, 1]$ i przeskalujemy ją następująco:

$$W(t) = x \cdot W'(t/x)$$

Takie skalowanie zmienia średni zakres wartości, co również może nie być zgodne z oczekiwaniami. Niemniej jednak w dalszej części pracy będziemy stosować właśnie tę konwencję.

Wyjaśnijmy jeszcze, skąd w nazwie bierze się słowo „spacer”. Zauważmy, że ograniczenie sumy do $\mathcal{L}$ pierwszych poziomów funkcji czapkowych spowodowało, że trajektoria SSL stała się funkcją kawałkami liniową.

Przypomnijmy sobie rozumowanie stojące za konstrukcją trajektorii ruchu Browna – każdy kolejny składnik sumy odpowiadał za ustalenie wartości w kolejnym punkcie diadycznym, a jednocześnie wpływał liniowo na sąsiednie punkty, tak aby zachować ciągłość. Ograniczenie się do n pierwszych składników powoduje, że nachylenie trajektorii może zmieniać się jedynie w n pierwszych punktach diadycznych. Pomiedzy tymi punktami trajektoria pozostaje liniowa.

Z tego właśnie powodu możemy traktować SSL jako rodzaj spaceru losowego – przyrosty trajektorii są wyznaczane w ustalonych, równomiernie rozmieszczonych punktach, a pomiędzy nimi funkcja porusza się liniowo. Zdefiniujmy więc formalnie kolejne „kroki” tego spaceru:

$$Z_k := W(k/n) - W((k-1)/n), \quad k = 1, 2, \dots, n \quad (*)$$

Kroki Z_k można więc interpretować jako losowe zmiany wartości trajektorii w kolejnych przedziałach, analogicznie jak w klasycznym spacerze losowym.

2.3 Probabilistyczne własności SSL

Przeanalizujmy teraz zachowanie zmiennych Z_k . Szczególnie istotną w kontekście algorytmów anonimizujących dane własnością jest logarytmiczne tempo odchyleń. Dla $k = 1, 2, \dots, n$ mamy:

$$\begin{aligned} \mathbb{E}[Z_1 + \dots + Z_k]^2 &= \mathbb{E}[W(k/n)]^2 = \mathbb{E}\left[\sum_{i=1}^n \phi_i(k/n) L_i\right]^2 = \sum_{i=1}^n \mathbb{E}[L_i^2] \phi_i(k/n)^2 = \\ &= 2(2\mathcal{L} + 1) \sum_{i=1}^n \phi_i(k/n)^2 \leq 2(2\mathcal{L} + 1)(\mathcal{L} + 1) = O(\mathcal{L}^3) = O(\log^3 n), \end{aligned}$$

gdzie trzecia i czwarta równość wynikają z faktu, że zmienne L_i są niezależne, mają wartość oczekiwaną równą 0 oraz wariancję równą $2(2\mathcal{L} + 1)$. Z kolei ostatnia nierówność wynika z tego, że każda funkcja ϕ_i przyjmuje wartości w przedziale $[0, 1]$, a dodatkowo – na każdym z $\mathcal{L} + 1$ poziomów – co najwyżej jedna z nich może być w danym punkcie różna od zera.

Jest to jedyna własność SSL, którą wymienili autorzy pracy [BSV24]. My przedstawimy jeszcze kilka z nich, aby lepiej zrozumieć ten proces.

Pokażemy teraz, że zmienne losowe Z_k mają ten sam rozkład, ale są silnie od siebie zależne. Zaczniemy od pierwszej z tych cech.

Zmienna losowa Z_k zależy od wartości zmiennych L_i , stojących przy tych funkcjach ϕ_i , dla których zachodzi nierówność $\phi_i(k/n) \neq \phi_i((k-1)/n)$. Na każdym poziomie dokładnie jedna funkcja spełnia tę własność. Zauważmy, że dla takiej funkcji zachodzi:

$$|\phi_i(k/n) - \phi_i((k-1)/n)| = 2^{l(i)}/n,$$

gdzie $l(i)$ oznacza poziom funkcji ϕ_i .

Zatem możemy zapisać:

$$Z_k \sim \frac{1 \cdot \text{Lap}(2\mathcal{L} + 1) + 2 \cdot \text{Lap}(2\mathcal{L} + 1) + 4 \cdot \text{Lap}(2\mathcal{L} + 1) + \dots + n \cdot \text{Lap}(2\mathcal{L} + 1)}{n}.$$

Wykorzystujemy tu symetrię rozkładu Laplace'a – znak wyrażenia $\phi_i(k/n) - \phi_i((k-1)/n)$ można wciągnąć do zmiennej L_i , nie zmieniając jej rozkładu.

Co istotne, to rozumowanie nie zależy od wyboru k . Informacja płynąca z k jest ukryta w znaku różnicy $\phi_i(k/n) - \phi_i((k-1)/n)$, co okaże się istotne przy obliczaniu kowariancji.

Kluczową obserwacją, istotną do jej wyznaczenia, jest fakt, że zmienne losowe Z_k i Z_p najpierw zawierają składnik L_1/n . Następnie, jeśli obie liczby k/n i p/n są mniejsze niż $1/2$ lub obie są większe niż $1/2$, to zmienne Z_k i Z_p zawierają składnik $2L_2/n$ (bądź $-2L_2/n$). Natomiast jeśli jedna z tych liczb jest mniejsza od $1/2$, a druga większa, to jedna ze zmiennych Z_k lub Z_p ma składnik $2L_2/n$, a druga $-2L_2/n$. Jeżeli obie miały ten sam znak składnika (tj. obie leżały po tej samej stronie „czapki” ϕ_2), to na następnym poziomie będzie na nie wpływała ta sama funkcja i rozumowanie można kontynuować. Jeśli jednak miały różne znaki, to na wszystkich następnych poziomach będą na nie działały różne funkcje, a zatem pozostałe wpływowe zmienne będą niezależne.

Aby dokładniej obliczyć $\text{Cov}(Z_k, Z_p)$, zapiszmy liczby $n+k-1$ oraz $n+p-1$ w systemie binarnym jako $k_{(2)}$ i $p_{(2)}$. Dodanie n sprawia, że reprezentacja binarna nie traci wiodących zer i zawsze zaczyna się od 1, co daje wygodną interpretację. Odjęcie 1 jest zabiegiem czysto technicznym, ponieważ wygodniej jest tu indeksować od zera.

Obserwacja jest teraz następująca: czytając od lewej, jeśli $k_{(2)}$ i $p_{(2)}$ mają w danym miejscu tę samą wartość, to na zmienne Z_k i Z_p wpływa ta sama funkcja (i to z tym samym znakiem). Natomiast w miejscu pierwszej rozbieżności ta sama funkcja wpływa już z przeciwnymi znakami, a wszystkie kolejne wpływające zmienne będą niezależne.

W ten sposób, oznaczając przez s pozycję pierwszej różnicy pomiędzy $k_{(2)}$ i $p_{(2)}$ (indeksując od zera), otrzymujemy:

$$\text{Cov}(Z_k, Z_p) = \sum_{i=0}^{s-1} \left[\left(\frac{2^i}{n} \right)^2 \cdot 2(2\mathcal{L} + 1) \right] - \left(\frac{2^s}{n} \right)^2 \cdot 2(2\mathcal{L} + 1),$$

gdzie $2(2\mathcal{L} + 1)$ jest wariancją zmiennych L_i .

Po zastosowaniu wzoru na sumę ciągu geometrycznego $\sum_{i=0}^{s-1} 4^i = \frac{4^s - 1}{3}$, otrzymujemy:

$$\text{Cov}(Z_k, Z_p) = \left[\frac{4^s - 1}{3} \cdot \left(\frac{1}{n^2} \right) - \frac{4^s}{n^2} \right] \cdot 2(2\mathcal{L} + 1) = \left(\frac{-2 \cdot 4^s - 1}{3n^2} \right) \cdot 2(2\mathcal{L} + 1).$$

Podsumowując, $Z_1, \dots, Z_n$ są zależnymi zmiennymi losowymi o tym samym rozkładzie, będącym kombinacją liniową zmiennych o rozkładzie Laplace’a.

Są one silnie skorelowane – zauważmy, że kowariancja jest zawsze ujemna, a jej wartość zależy mocno od tego, jak blisko siebie znajdują się zmienne. Wyjaśnia to zjawisko, które obserwowaliśmy na rysunku 3, gdzie po nagłych wzrostach następowały nagłe spadki. Obserwowany trend jest natomiast wynikiem wpływu kilku pierwszych poziomów, na których zmiany nie są gwałtowne, lecz rozciągnięte w czasie.

Pomimo dużych wahań, asymptotycznie spacer oddala się od punktu startowego wolniej, niż gdyby jego kroki były zmiennymi niezależnymi o tym samym rozkładzie.

2.4 Szereg nieskończony

Pomimo że SSL definiowaliśmy podobnie do ruchu Browna, to jednak myśleliśmy o nim jak o spacerze losowym. Ten podrozdział poświęcimy rozważeniu podobnej konstrukcji, tym razem powracając do szeregu nieskończonego.

Zauważmy najpierw, że zwykłe zastąpienie n znakiem nieskończoności nie wystarczy. Dokładniej, jeśli $L_i \sim \text{Lap}(\lambda)$, to:

$$\sum_{i=1}^{\infty} L_i \phi_i = \infty \quad (\text{prawie na pewno}).$$


Wynika to z faktu, że każdy składnik sumy dodaje w tym punkcie zmienną o rozkładzie $\text{Lap}(\lambda)$. Gdyby szereg ten był zbieżny punktowo, to dla dowolnego $\varepsilon > 0$ od pewnego indeksu wszystkie kolejne składniki musiałyby wpadać do paska o szerokości ε , co tu nie zachodzi na mocy lematu Borela–Cantellego.

Problemem okazuje się brak skalowania parametru λ tak jak robiliśmy to w przypadku ruchu Browna. Dodajmy je definiując:

$$W(t) := \sum_{i=1}^{\infty} L_i \phi_i(t), \quad L_1 \sim \text{Lap}(1); \quad L_i \sim \text{Lap}(2^{(-l(i)-1)/2}), \quad i = 2, 3, \dots$$

Jest to podobne skalowanie do tego, które zostało wykorzystane wcześniej. Szereg ten, na mocy twierdzenia o dwóch szeregach, jest zbieżny prawie na pewno. Proste rachunki pokazują, że wówczas dla $t \in [0, 1]$, $\text{Var}(W(t)) = 2t$.

Skoro trajektoria tego procesu jest dobrze zdefiniowana, nazwijmy go ruchem Laplace’a.



Rysunek 4: Trajektoria ruchu Laplace’a i ruchu Browna.

Zobaczmy, jak wyglądają trajektorie ruchu Laplace'a. Patrząc na rysunek 4, można odnieść wrażenie, że proces ten niewiele różni się od zwykłego ruchu Browna.

Aby dostrzec różnice, przyjrzyjmy się, które z czterech klasycznych warunków definicji ruchu Browna są spełnione przez ruch Laplace'a. Oczywiście mamy $W(0) = 0$, a trajektoria procesu jest ciągła prawie na pewno. Pokażemy jednak, że dwa pozostałe warunki tj. stacjonarność i niezależność przyrostów (w odpowiedniku, w którym rozkład normalny zastępujemy rozkładem Laplace'a) nie są spełnione.

Lemat. Przyrosty ruchu Laplace'a nie są stacjonarne. Innymi słowy, istnieją takie liczby $t, s, k > 0$, że $W(t) - W(s) \not\sim W(t+k) - W(s+k)$.

Dowód. Weźmy $t = 1/2$, $s = 0$, $k = 1/4$. Chcemy więc pokazać, że rozkład $W(1/2)$ jest różny od rozkładu $W(3/4) - W(1/4)$. Na wartość w punkcie $1/2$ wpływają jedynie dwa pierwsze składniki szeregu, a więc $W(1/2) = 1/2 \cdot L_1 + L_2 \sim 1/2 \cdot \text{Lap}(1) + \text{Lap}(1/2) \sim \text{Lap}(1/2) + \text{Lap}(1/2)$, gdzie ostatnia równość rozkładów wynika z tego, że $a \cdot \text{Lap}(b) \sim \text{Lap}(ab)$. Na wartości w punktach $1/4$ i $3/4$ wpływają pierwsze cztery składniki szeregu, jednak wpływ składnika $L_2\phi_2$ jest taki sam, zatem nie ma on znaczenia przy wyznaczaniu różnicy. Stąd $W(3/4) - W(1/4) = 1/2 \cdot L_1 - L_3 + L_4 \sim \text{Lap}(1/2) + \text{Lap}(1/2\sqrt{2}) + \text{Lap}(1/2\sqrt{2})$. Zatem gdyby $W(1/2) \sim W(3/4) - W(1/4)$, to po przekształceniach $\text{Lap}(1) \sim \text{Lap}(1/\sqrt{2}) + \text{Lap}(1/\sqrt{2})$. Załóżmy nie wprost, że tak jest. Wówczas:

$$\text{Lap}(\lambda) \sim \frac{\text{Lap}(\lambda) + \text{Lap}(\lambda)}{\sqrt{2}} \sim \frac{\text{Lap}(\lambda) + \text{Lap}(\lambda) + \text{Lap}(\lambda) + \text{Lap}(\lambda)}{\sqrt{4}} \sim \frac{\sum_{i=1}^n \text{Lap}(\lambda)}{\sqrt{n}},$$

gdzie ostatnie wyrażenie – na mocy centralnego twierdzenia granicznego – zbiega według rozkładu do $\mathcal{N}(0, 2\lambda^2)$ co jest oczywiście sprzeczne. $\square$

Lemat. Przyrosty ruchu Laplace'a nie są niezależne. Innymi słowy, istnieją takie liczby $t, s > 0$, że zmienne $W(t) - W(s)$ oraz $W(s)$ są zależne.

Dowód. Weźmy $t = 1$, $s = 1/2$. Chcemy więc pokazać, że zmienne $W(1) - W(1/2)$ oraz $W(1/2)$ są zależne. Zauważmy, że $W(1) = L_1$, $W(1/2) = 1/2 \cdot L_1 + L_2$, zatem, oznaczając przez $X = 1/2 \cdot L_1$, $Y = L_2$, otrzymujemy: $W(1) - W(1/2) = X - Y$, $W(1/2) = X + Y$. Ponadto $X \sim Y \sim \text{Lap}(1/2)$. Będziemy rozważać funkcje charakterystyczne zmiennych $X + Y$ oraz $X - Y$. Przypomnijmy: jeśli $X + Y$ i $X - Y$ są niezależne, to $\varphi_{X+Y}(t) \cdot \varphi_{X-Y}(t) = \varphi_{2X}(t)$. Ponieważ X i Y są niezależne, to:

$$\varphi_{X+Y}(t) = \varphi_X(t) \cdot \varphi_Y(t) = \frac{4}{4+t^2} \cdot \frac{4}{4+t^2} = \left(\frac{4}{4+t^2} \right)^2.$$

Jako że rozkład Y jest symetryczny, to również $\varphi_{X-Y}(t) = \left(\frac{4}{4+t^2} \right)^2$. Pozostaje wyliczyć, że:

$$\varphi_{2X}(t) = \frac{1}{1+t^2} \neq \left(\frac{4}{4+t^2} \right)^2 \cdot \left(\frac{4}{4+t^2} \right)^2 = \varphi_{X+Y}(t) \cdot \varphi_{X-Y}(t),$$

a zatem zmienne $X + Y$ i $X - Y$ nie są niezależne, a tym samym zmienne $W(1) - W(1/2)$ oraz $W(1/2)$ nie są niezależne. $\square$

3 Algorytmy anonimizujące dane

Rozdział ten poświęcony jest dwóm algorytmom anonimizującym dane – schematowi Laplace’a (opisanemu w książce [DR14]) oraz jego modyfikacji wykorzystującej SSL (opisanej w pracy [BSV24]). Używamy określenia „modyfikacja”, ponieważ oba algorytmy bazują na tej samej idei, choć na pierwszy rzut oka może to nie być oczywiste.

3.1 Ogólny schemat algorytmu

Skoro oba algorytmy opierają się na podobnej idei, zacznijmy od przedstawienia ogólnego schematu ich działania. Wprowadzimy najpierw kilka oznaczeń:

- (T, ρ) – ustalona ograniczona przestrzeń metryczna, z której pochodzą dane,
- ε – ustalony poziom prywatności, który będziemy chcieli uzyskać – liczba większa od 0,
- $\mathcal{D}_X$ – wejściowa baza danych, którą będziemy chcieli zanonimizować – zakładamy, że jest to multizbiór (czyli zbiór z możliwymi duplikatami) wektorów z T ,
- $\mathcal{D}_Y$ – wyjściowa baza danych, wynik algorytmu – ponownie multizbiór wektorów z T ,
- n – wielkość $\mathcal{D}_X$; dana na wejściu,
- m – wielkość $\mathcal{D}_Y$; stała ustalona przez nas, niezależna od n – sensownym jest jednak, aby m i n miały podobny rząd wielkości,
- $\mathcal{A}$ – algorytm przekształcający $\mathcal{D}_X$ w $\mathcal{D}_Y$ – naszym celem będzie jego skonstruowanie.

Algorytm $\mathcal{A}$ skonstruujemy poprzez zestawienie mniejszych, prostszych algorytmów, które krok po kroku będą przekształcały $\mathcal{D}_X$, aż do uzyskania $\mathcal{D}_Y$. Ogólność tego schematu będzie polegała na tym, że jeden z etapów (choć kluczowy) będzie realizowany w różny sposób w zależności od konkretnego algorytmu.

Zacznijmy od tego, że operowanie na multizbiorach bywa niewygodne, dlatego zamiast $\mathcal{D}_X$ posłużymy się miarą empiryczną μ_X . Definiujemy ją jako sumę miar jednopunktowych na wszystkich elementach z $\mathcal{D}_X$, podzieloną przez n , aby otrzymać miarę probabilistyczną.

Pojawia się tu jednak pewien problem, który stanie się istotny na dalszym etapie konstrukcji – chcielibyśmy, aby przestrzeń, na której określona jest miara μ_X , była zbiorem skończonym. Najwygodniejszym rozwiązaniem tego problemu jest tzw. dyskretyzacja przestrzeni T . Polega ona na wyborze skończonego podzbioru T w taki sposób, by punkty były rozłożone możliwie „równomiernie”, ale jednocześnie by nie było ich zbyt wiele. Przykładem takiej dyskretyzacji są δ -sieci, które – dzięki założeniu o ograniczoności przestrzeni T – są skończone. W związku z tym dodajmy do wcześniejszej listy dwa dodatkowe oznaczenia:

- $\Omega = \{\omega_1, \dots, \omega_N\}$ – skończony podzbiór T ,
- N – liczba elementów zbioru Ω .

Mając miarę empiryczną μ_X , chcielibyśmy przekształcić ją w miarę empiryczną na Ω (nazwijmy ją $\mu_{X(T)}$) w taki sposób, aby nie uległa ona zbyt dużej zmianie. Aby lepiej zrozumieć, co dokładnie oznacza sformułowanie „nie uległa zbyt dużej zmianie”, wprowadzimy pojęcie odległości Wassersteina, mierzącej dystans pomiędzy miarami.

Definicja. Niech (T, ρ) będzie przestrzenią metryczną, zaś μ, ν dwiema miarami probabilistycznymi na T . *Odległość Wassersteina rzędu pierwszego* pomiędzy μ a ν definiujemy jako:

$$W_1(\mu, \nu) := \inf_{\pi \in \Pi(\mu, \nu)} \int_{T \times T} \rho(x, y) d\pi(x, y),$$

gdzie $\Pi(\mu, \nu)$ oznacza zbiór wszystkich miar na $T \times T$, takich że μ i ν są miarami brzegowymi.

Intuicyjnie, powyższa definicja minimalizuje *koszt transportu* pomiędzy „kupkami ziemi” reprezentowanymi przez miary μ i ν .

Chcielibyśmy teraz przekształcić μ_X w $\mu_{X(T)}$ w taki sposób, aby zminimalizować odległość Wassersteina między nimi. Aby to zrobić, przenieśmy masę z każdego punktu x , dla którego $\mu_X(x) > 0$, do najbliższego mu (w sensie metryki ρ) punktu z Ω . Zauważmy, że wybór najbliższego punktu jest uzasadniony, ponieważ – w duchu intuicji stojącej za odległością W_1 – w ten sposób minimalizujemy koszt transportu tej części „ziemi”, którą i tak musimy gdzieś przenieść.

Kolejnym – i zarazem najważniejszym – etapem będzie odpowiednie zaburzenie miary probabilistycznej $\mu_{X(T)}$. Niech $U_1, \dots, U_N$ będą pewnymi zmiennymi losowymi (ich rozkład zależeć będzie od wybranej metody). Zdefiniujmy wówczas:

$$\mu_{Z\pm}(\omega_i) := \mu_{X(T)}(\omega_i) + U_i, \quad i = 1, 2, \dots, N.$$

Każdy z opisanych później algorytmów będzie realizował to zaburzenie w inny sposób. Co istotne, jest to jedyne miejsce w całym procesie, w którym wykorzystywana jest losowość², zatem prywatność całego algorytmu zależy od tego, czy to przekształcenie jest prywatne.

Zauważmy jedną bardzo ważną rzecz – ze względu na zaburzenia, miara $\mu_{Z\pm}$ przestała być miarą probabilistyczną, a co gorsza – stała się miarą znakową (stąd oznaczenie z symbolem $\pm$). Kolejnym krokiem będzie powrót do miary probabilistycznej μ_Z w taki sposób, aby odległość W_1 między nimi była jak najmniejsza. Autorzy pracy [BSV24] opisują to przejście jako *liniowy problem optymalizacyjny* – przyjrzymy się mu w kolejnym rozdziale, poświęconemu implementacji obu algorytmów.

Mając już zaburzoną miarę probabilistyczną μ_Z , pozostaje skonstruować z niej bazę danych $\mathcal{D}_Y$. Nie bez powodu jednak używaliśmy litery Z zamiast Y do oznaczania miar – konieczne jest bowiem wykonanie jeszcze jednego przejścia: najpierw przekształcimy miarę μ_Z w miarę empiryczną μ_Y , a następnie zamienimy ją w $\mathcal{D}_Y$, analogicznie jak wcześniej $\mathcal{D}_X$ zamieniliśmy w μ_X .

Pierwsze z przekształceń wykonamy, zmniejszając masę w każdym punkcie z Ω do wielokrotności $1/m$. Dokładniej:

$$\mu_{Y'}(\omega_i) := \frac{\lfloor m \cdot \mu_Z(\omega_i) \rfloor}{m}$$

W ten sposób „zgubiliśmy” część masy – aby otrzymać miarę μ_Y , możemy albo dodać brakującą masę do ω_1 , albo rozdzielić ją losowo między wszystkie punkty, każdorazowo dodając gdzieś $1/m$.

Ostatnim krokiem jest wspomniana wcześniej zamiana miary μ_Y w bazę danych $\mathcal{D}_Y$. Tym samym kończymy konstrukcję ogólnego schematu algorytmów anonimizujących dane – przejdźmy teraz do konkretnych przykładów tych algorytmów oraz sposobów realizacji przejścia z $\mu_{X(T)}$ do $\mu_{Z\pm}$.

²Tak naprawdę losowość pojawi się później w jednym z kroków algorytmu – niemniej jednak będzie ona znikoma lub ten krok będzie można wykonać deterministycznie.

3.2 Schemat Laplace'a

Zacznijmy od znacznie prostszego z algorytmów – schematu Laplace'a, opisanego w książce [DR14]. Naszym celem jest skonstruowanie ciągu zmiennych losowych $U_1, \dots, U_N$ i dokonanie zaburzenia:

$$\mu_{Z\pm}(\omega_i) := \mu_{X(T)}(\omega_i) + U_i, \quad i = 1, 2, \dots, N.$$

W tym przypadku konstrukcja będzie wyjątkowo prosta – przyjmujemy, że $U_1, \dots, U_N$ to ciąg niezależnych zmiennych losowych o rozkładzie Laplace'a $\text{Lap}(2/\varepsilon n)$.

Twierdzenie. Schemat Laplace'a jest ε -różnicowo prywatny.

Dowód. Weźmy dwie bazy danych $\mathcal{D}_X$ oraz $\mathcal{D}'_X$, różniące się co najwyżej jedną obserwacją. Oznaczmy przez $\mu_{X(T)}$ oraz $\mu'_{X(T)}$ odpowiadające im miary empiryczne na zbiorze Ω . Jako, że pozostałe kroki są deterministyczne, wystarczy pokazać ε -różnicową prywatność samego zaburzenia. Niech:

$$\bar{\mu}_{X(T)} := (\mu_{X(T)}(\omega_1), \dots, \mu_{X(T)}(\omega_N)), \quad \bar{\mu}'_{X(T)} := (\mu'_{X(T)}(\omega_1), \dots, \mu'_{X(T)}(\omega_N)).$$

Zauważmy, że:

$$\|\bar{\mu}_{X(T)} - \bar{\mu}'_{X(T)}\|_1 \leq \frac{2}{n},$$

gdzie:

$$\|\bar{\mu}\|_1 := \sum_{i=1}^N |\mu(\omega_i)|.$$

Do każdej współrzędnej $\bar{\mu}_{X(T)}(\omega_i)$ dodajemy niezależną zmienną losową $U_i \sim \text{Lap}(2/\varepsilon n)$. Niech:

$$\bar{\mu}_{Z\pm} := \bar{\mu}_{X(T)} + U.$$

Weźmy dowolny zbiór mierzalny $S \subset \mathbb{R}^N$. Chcemy pokazać, że:

$$\mathbb{P}[\bar{\mu}_{Z\pm} \in S] \leq \exp(\varepsilon) \cdot \mathbb{P}[\bar{\mu}'_{Z\pm} \in S].$$

Rozkład Laplace'a w $\mathbb{R}^N$ (dla niezależnych współrzędnych) ma gęstość:

$$f_U(u) = \prod_{i=1}^N \frac{\varepsilon n}{4} \exp\left(-\frac{\varepsilon n}{2} \cdot |u_i|\right).$$

Zatem stosunek gęstości rozkładów dla $z \in \mathbb{R}^N$ wynosi:

$$\begin{aligned} \frac{f_{\mu_{Z\pm}}(z)}{f_{\mu'_{Z\pm}}(z)} &= \frac{f_U(z - \bar{\mu}_{X(T)})}{f_U(z - \bar{\mu}'_{X(T)})} = \prod_{i=1}^N \exp\left(\frac{\varepsilon n}{2} \cdot (|z_i - \mu'_{X(T)}(\omega_i)| - |z_i - \mu_{X(T)}(\omega_i)|)\right) \leq \\ &\leq \prod_{i=1}^N \exp\left(\frac{\varepsilon n}{2} \cdot |\mu_{X(T)}(\omega_i) - \mu'_{X(T)}(\omega_i)|\right) = \exp\left(\frac{\varepsilon n}{2} \cdot \|\bar{\mu}_{X(T)} - \bar{\mu}'_{X(T)}\|_1\right) \leq \exp(\varepsilon), \end{aligned}$$

gdzie najpierw użyliśmy nierówności trójkąta, a potem tego, że: $\|\bar{\mu}_{X(T)} - \bar{\mu}'_{X(T)}\|_1 \leq 2/n$. $\square$

3.3 Algorytm wykorzystujący SSL

Przyjrzyjmy się teraz drugiemu algorytmowi – nie będzie tajemnicą, że zmienne losowe będziemy chcieli uzyskać za pomocą konstrukcji SSL. Niech $\mathcal{L}$ będzie najmniejszą liczbą naturalną spełniającą nierówność $2^{\mathcal{L}} \geq N$. Skonstruujemy SSL na $\mathcal{L}$ poziomach, otrzymując zmienne $Z_1, \dots, Z_{2^{\mathcal{L}}}$ zgodnie z (*). Weźmy pierwsze N z nich i przeskalujemy w następujący sposób:

$$U_i := \frac{2}{\varepsilon n} \cdot Z_i, \quad i = 1, \dots, N.$$

Zwróćmy uwagę na pewne podobieństwo do zmiennych w schemacie Laplace’a – tam zmienne $U_1, \dots, U_N$ miały rozkład $U_i \sim 2/\varepsilon n \cdot \text{Lap}(1)$. Teraz analogiczne zmienne mają rozkład

$$U_i \sim \frac{2}{\varepsilon n} \cdot \frac{1 \cdot \text{Lap}(2^{\mathcal{L}} + 1) + 2 \cdot \text{Lap}(2^{\mathcal{L}} + 1) + 4 \cdot \text{Lap}(2^{\mathcal{L}} + 1) + \dots + N \cdot \text{Lap}(2^{\mathcal{L}} + 1)}{N}.$$

Widzimy, że ten drugi zestaw zmiennych ma znacznie większą wariancję, co rodzi następujące pytania:

1. Dlaczego w tym przypadku konieczne jest dodanie tak dużej ilości szumu?
2. Dlaczego jakość zaburzonych danych nie ulega przez to znaczącemu pogorszeniu?

Okazuje się, że odpowiedzi na oba pytania wynikają z silnych korelacji pomiędzy wygenerowanymi zmiennymi. Z jednej strony korelacje te wymuszają dodanie większej ilości szumu w celu zachowania ε -różnicowej prywatności. Z drugiej jednak strony – dzięki odpowiednio zaprojektowanej strukturze oraz kolejności zaburzania miary $\mu_{X(T)}$ – pozwalają one na znacznie mniejsze zakłócenie ogólnej struktury bazy danych niż w przypadku niezależnego zaburzania każdej współrzędnej. Taki zabieg jest możliwy dzięki temu, że sumaryczna wariancja zmiennych losowych pochodzących z SSL jest logarytmiczna względem ich ilości.

Jak już wspomnieliśmy, ze względu na dużą korelację między kolejnymi zmiennymi, krytyczną rolę odgrywa kolejność ich dodawania do miary $\mu_{X(T)}$. Przez „kolejność dodawania” rozumiemy tutaj pewne przeindeksowanie elementów zbioru $\Omega = \{\omega_1, \dots, \omega_N\}$, które wpływa na sposób przypisania kolejnych zmiennych losowych do odpowiednich punktów przestrzeni.

W pracy [BSV24] znaleźć możemy wynik, zgodnie z którym ostateczna jakość zaburzonych danych zależy liniowo od sumarycznej odległości pomiędzy kolejnymi punktami, tzn.

$$\mathbb{E}[W_1(\mu_X, \mu_Y)] \sim \sum_{i=1}^{N-1} \rho(\omega_i, \omega_{i+1}).$$

Przedstawmy teraz intuicję stojącą za tym rezultatem. Przypomnijmy jedną z charakterystycznych własności SSL – po nagłych skokach następują równie nagłe spadki. Dodanie do jednego punktu dużej wartości i jednocześnie odjęcie podobnej wartości od sąsiedniego punktu daje efekt niewielkiego „przesunięcia masy”. Zauważmy, że gdyby zmienne były dodawane w losowej kolejności, nie osiągnęlibyśmy takiego efektu – zamiast tego obserwowalibyśmy losowe zaniki i pojawienia się masy, podobnie jak ma to miejsce w schemacie Laplace’a, lecz na znacznie większą skalę, co znacząco pogorszyłoby jakość danych.

Oczywiście chcemy, aby średnia odległość Wassersteina rzędu pierwszego W_1 pomiędzy miarami μ_X i μ_Y była możliwie najmniejsza – wówczas jakość otrzymanych danych będzie najwyższa. Jak zatem znaleźć optymalną kolejność zaburzania? Problem ten sprowadza się do rozwiązania problemu komiwojażera na przestrzeni Ω . Problem komiwojażera jest NP-zupełny, co oznacza, że nie znamy szybkiego (w sensie wielomianowym) algorytmu rozwiązującego go dokładnie, a wręcz spodziewamy się, że taki algorytm nie istnieje.

Istnieją jednak szybkie algorytmy aproksymacyjne (tzn. dające rozwiązanie gorsze od optymalnego co najwyżej o stały czynnik). Przykładowo, algorytm 2-aproksymacyjny można wykonać w czasie $O(N^2 \log N)$, co jest czasem akceptowalnym w praktyce.

Oczywiście powyższe dotyczy problemu w ogólnej przestrzeni metrycznej (T, ρ) . W wielu zastosowaniach sytuacja jest znacznie prostsza – na przykład, gdy $T = [-M, M]^k$, a dyskretyzacja polega na wyborze punktów kratowych, znalezienie optymalnej kolejności może być trywialne dzięki naturalnej strukturze geometrycznej przestrzeni.

Twierdzenie. Powyższy algorytm jest ε -różnicowo prywatny.

Dowód tego twierdzenia stanowi znaczną część pracy [BSV24] i nie będziemy go powtarzać.

4 Eksperymenty

Po szczegółowym skonstruowaniu obu algorytmów postanowiliśmy zweryfikować ich użyteczność w praktyce. W tym rozdziale najpierw omówimy dokładniej wybrane problemy związane z ich implementacją, a następnie przeprowadzimy eksperymenty na wybranym zbiorze danych w celu oceny jakości danych zaburzonych.

4.1 Implementacja SSL

Zacznijmy od implementacji SSL, a dokładniej od wyznaczenia ciągu $Z_1, \dots, Z_n$.

Zauważmy, że dla danej funkcji czapkowej możemy wyprowadzić jawny wzór na jej wartość w zadanym punkcie. Niech $\phi_{(L,R)}$ będzie funkcją czapkową, której „czapka” znajduje się nad przedziałem (L, R) – dokładniej, $\phi_{(L,R)}(x) > 0 \iff x \in (L, R)$. Wtedy:

$$\phi_{(L,R)}(x) = \max\left(0, 1 - \left|\frac{x - M}{L - M}\right|\right), \quad M = \frac{L + R}{2}.$$

Zatem mając przedział, możemy wyznaczyć wartość przypisanej mu funkcji w czasie stałym.

Skonstruujmy teraz przypisanie $f(i) = (L_i, R_i)$, gdzie $\phi_i = \phi_{(L_i, R_i)}$. Można je wyznaczyć w czasie $O(n)$, ponieważ kolejne przedziały zależą jedynie od poziomu funkcji ($l(i) = \lceil \log_2(i) \rceil$) oraz od pozycji funkcji w jej poziomie (co można wyznaczyć, wykonując odpowiednią operację dzielenia bez reszty).

Mając to przypisanie, możemy w naiwny sposób skonstruować zmienne $Z_1, \dots, Z_n$ poprzez wyznaczenie wartości SSL w kolejnych punktach. Wystarczy w każdym punkcie obliczyć wartość każdej funkcji czapkowej, a następnie wszystko zsumować. Całość zajmuje $O(n^2)$ czasu.

Niestety, nawet dla stosunkowo małych zbiorów danych (np. niecałych 50 tysięcy obserwacji) takie rozwiązanie nie jest akceptowalne. Można jednak je w prosty sposób zoptymalizować do czasu $O(n \log n)$, który jest już w pełni akceptowalny. Wystarczy zauważyć, że na wartość SSL w danym punkcie wpływa maksymalnie po jednej funkcji czapkowej z każdego poziomu. Zatem mając dany punkt oraz poziom, chcemy w czasie stałym wyznaczyć indeks funkcji z tego poziomu, która wpływa na wartość w tym punkcie. Okazuje się, że wystarczy – podobnie jak wcześniej – obliczyć przesunięcie w obrębie danego poziomu, a następnie dodać do niego łączną liczbę funkcji na poziomach niższych. Tym samym dla każdego punktu (których jest n) wykonamy tyle operacji, ile wynosi liczba poziomów, czyli $\log_2 n$.

Co ciekawe, konstrukcję SSL można zaimplementować w czasie $O(n)$. Aby to zrobić, należy wyznaczać kolejne wartości SSL w odpowiedniej kolejności – konkretnie, w kolejnych punktach diadycznych. Wartości w punktach 0 i 1 są łatwe do obliczenia, natomiast wartość w dowolnym punkcie diadycznym wyznacza się jako sumę średniej arytmetycznej wartości w sąsiednich punktach oraz zmiennej o rozkładzie Laplace’a z odpowiednio dobranym parametrem.

4.2 Przejście z miary znakowej na miarę probabilistyczną

Powróćmy teraz do zagadnienia, które wcześniej pominęliśmy. Mając daną miarę znakową μ , chcemy przekształcić ją w miarę probabilistyczną μ' w taki sposób, aby odległość $W_1(\mu, \mu')$ była możliwie najmniejsza.

Autorzy pracy [BSV24] zauważają, że problem ten można sformułować jako liniowy problem optymalizacyjny. Znany algorytm należący do tej klasy problemów, którego szkic można by tu przedstawić, działa w czasie $O(N^2)$. Jak już wcześniej wspomnieliśmy, taki koszt obliczeniowy jest nieakceptowalny dla dużych zbiorów danych.

Niestety, nie udało nam się opracować algorytmu, który rozwiązywałby ten problem dokładnie w czasie asymptotycznie lepszym.

Udało się jednak zaprojektować rozwiązanie heurystyczne – nieoptymalne, ale w praktyce dające dobre rezultaty. Choć nie jesteśmy w stanie zagwarantować ograniczenia błędu (istnieją przykłady brzegowe, dla których błąd może być znaczny), to jednak w większości przypadków aproksymacja okazuje się wystarczająco dokładna.

Idea proponowanego podejścia jest następująca: dla każdego punktu o ujemnej masie wykonujemy dwie operacje – ustawiamy wartość w tym punkcie na zero, a następnie próbujemy odjąć dodaną w ten sposób masę z jego najbliższego otoczenia. W wyniku tego procesu otrzymujemy nową miarę, którą można następnie przeskalować, aby uzyskać miarę probabilistyczną.

Uzasadnieniem takiego podejścia jest wcześniej opisana intuicja związana z lokalnym przesuwaniem masy. Niestety, przeprowadzenie pełnej analizy matematycznej tej heurystyki okazuje się niezwykle trudne i technicznie skomplikowane. Z tego względu – jak to często bywa w przypadku metod heurystycznych – najlepszym sposobem oceny jej jakości pozostaje weryfikacja empiryczna.

4.3 Porównanie algorytmów

Aby ocenić jakość zaburzonych danych, zastosujemy następującą procedurę: posłużymy się rzeczywistym zbiorem danych, na którym przeprowadzimy proces zaburzania zgodnie z opisanymi wcześniej algorytmami, a następnie porównamy skuteczność klasyfikatora wytrenowanego na danych oryginalnych i zaburzonych. Pozwoli to ocenić, która z metod anonimizacji lepiej zachowuje istotne własności statystyczne bazy danych.

Przedstawmy teraz warunki, w których porównywane były oba algorytmy.

Jako zbiór danych wybraliśmy dane pochodzące z amerykańskiego spisu powszechnego. Zawierają one informacje o dochodach oraz cechach demograficznych, takich jak wiek, liczba lat edukacji czy liczba godzin pracy tygodniowo, dla prawie 50 tysięcy obywateli USA.

Dane podzielone są na dwie klasy: osoby o dochodach powyżej 50 tysięcy dolarów oraz osoby, których dochody tej wartości nie przekraczają. Zbiór jest niezbalansowany – jedynie około 1/4 obserwacji należy do pierwszej z wymienionych klas.

Zdecydowaliśmy się na podział danych na zbiór treningowy (losowo wybrane 75% całego zbioru z zachowaniem proporcji klas) oraz zbiór testowy (pozostałe 25%).

Sposób zaburzania danych w zbiorze treningowym był następujący: najpierw podzieliliśmy dane według klas, następnie każdą z części zaburziliśmy jednym z opisanych wcześniej algorytmów, a na końcu połączyliśmy obie zaburzone części w jedną bazę danych. Taki podział jest konieczny, ponieważ inaczej nie byłoby wiadomo, jaką klasę przypisać nowym obserwacjom.

Dla obu algorytmów zastosowaliśmy te same parametry m_1 i m_2 (po jednym dla każdej klasy). Ponadto ustaliliśmy poziom prywatności $\varepsilon = 0,1$.

Poza różnicą w sposobie zaburzania miary $\mu_{X(T)}$, oba algorytmy działały identycznie – w szczególności, w obu zastosowaliśmy to samo heurystyczne podejście przejścia z miary znakowej na probabilistyczną.

Jako metodę oceny jakości wykorzystaliśmy klasyfikator KNN z wagami, wytrenowany na każdej z wersji zaburzonego zbioru treningowego. Następnie przy jego pomocy przewidywana była klasa dla obserwacji ze zbioru testowego. Zmierzone zostały dwie metryki: celność (ang. accuracy), definiowana jako odsetek poprawnie sklasyfikowanych obserwacji, oraz miara F1, która uwzględnia zarówno precyzję, jak i czułość w wykrywaniu danej klasy.

Dla porównania, analogiczne pomiary zostały wykonane również dla danych niezaburzonych, aby ocenić trudność samego zadania klasyfikacji na tym zbiorze danych.

4.4 Wyniki

Otrzymane wyniki przedstawia Tabela 1. Dla każdego z trzech rozważanych przypadków – danych niezaburzonych, danych zaburzonych według klasycznego schematu Laplace’a oraz danych przetworzonych z wykorzystaniem algorytmu opartego na SSL – zmierzaliśmy celność klasyfikatora oraz wartości miary F1 osobno dla każdej z klas.

	Celność	F1 dla $\leq 50K$	F1 dla $> 50K$
Brak zaburzenia	0,72	0,80	0,51
Schemat Laplace’a	0,64	0,76	0,29
Algorytm z SSL	0,58	0,70	0,30

Tabela 1: Wartości poszczególnych metryk dla różnych wersji zbioru danych.

Zgodnie z oczekiwaniami, najlepsze wyniki osiągnięto w przypadku danych niezaburzonych. Zarówno celność, jak i obie wartości F1 są wyraźnie wyższe niż w przypadkach zastosowania mechanizmów anonimizacji.

Zaburzenie danych według klasycznego schematu Laplace’a skutkuje wyraźnym pogorszeniem jakości klasyfikacji, szczególnie dla rzadszej klasy ($> 50K$), gdzie wartość F1 spada z 0,51 do 0,29.

Algorytm oparty na SSL osiąga nieco niższą celność ogólną niż schemat Laplace’a, jednak wartość F1 dla klasy rzadkiej jest porównywalna, a nawet nieznacznie wyższa (0,30). Świadczy to o nieco lepszym balansie między klasami, co – z punktu widzenia wielu zastosowań – może być korzystniejsze.

Wyniki te potwierdzają, że pomimo silnego zaburzenia danych (niska wartość ε), algorytm oparty na SSL pozwala uzyskać zadowalającą jakość klasyfikacji, szczególnie przy uwzględnieniu priorytetu ochrony prywatności oraz trudności samego zadania klasyfikacyjnego.

Odpowiedzmy jeszcze na nasuwające się pytanie: dlaczego algorytm wykorzystujący SSL uzyskał gorsze wyniki niż prosty schemat Laplace’a? Potencjalnych przyczyn jest wiele – poniżej przedstawiamy dwie, które uważamy za najbardziej prawdopodobne.

Po pierwsze, istotną rolę może odgrywać rozmiar zbioru danych. Algorytm oparty na SSL wykazuje swoje zalety głównie w przypadku bardzo dużych zbiorów, ponieważ asymptotycznie zapewnia mniejsze sumaryczne zaburzenie. Wybór zbioru zawierającego niespełna 50 tysięcy obserwacji mógł okazać się niewystarczający do zaobserwowania tej przewagi.

Drugim możliwym czynnikiem jest jakość zastosowanego podejścia heurystycznego. W trakcie eksperymentów zauważyliśmy, że dla danych przetwarzanych algorytmem SSL uzyskiwana aproksymacja miary probabilistycznej była znacząco mniej dokładna niż w przypadku klasycznego schematu, co mogło bezpośrednio przełożyć się na spadek jakości klasyfikacji.

Podsumowując, kwestia porównania jakości działania obu algorytmów pozostaje otwarta. Wykazaliśmy jednak, że oba podejścia – mimo silnego ograniczenia prywatności ($\varepsilon = 0,1$) – pozwalają zachować zadowalający poziom użyteczności danych, co może stanowić podstawę do ich dalszego stosowania w praktyce.

Literatura

- [BSV24] March Boedihardjo, Thomas Strohmer, and Roman Vershynin. Private measures, random walks, and synthetic data. *Probability Theory and Related Fields*, 189(1–2):569–611, 2024.
- [DR14] Cynthia Dwork and Aaron Roth. The algorithmic foundations of differential privacy. *Foundations and Trends® in Theoretical Computer Science*, 9(3–4):211–407, 2014.